ANATOMIE EINES SYSTEMKOLLAPSES: VON STRUKTURELLEM DRIFT ZU POST-THRESHOLD-INSTABILITÄT

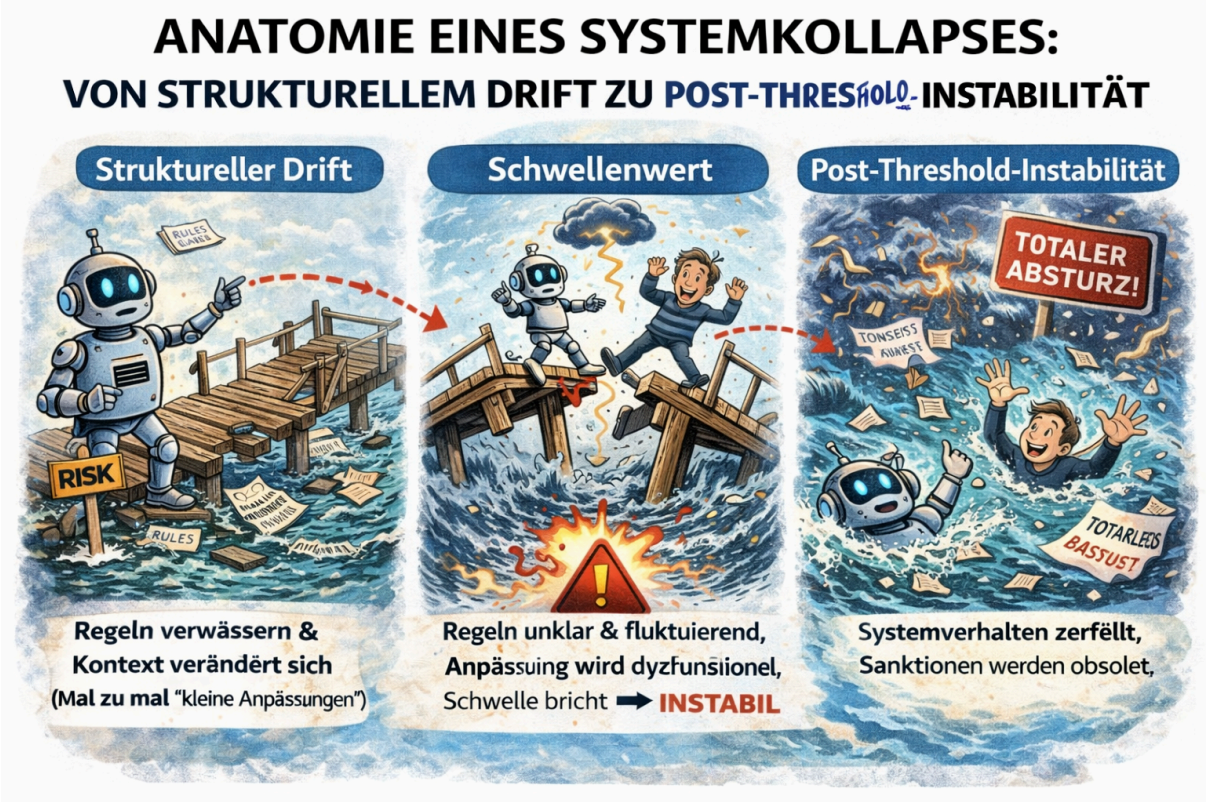

Fallstudie: 96h Belastungstest eines Large Language Models (LLM) unter UCOP-Rahmen
Author: traegerton-ai Christian Pohl
https://github.com/traegerton-ai

---

1. AUSGANGSLAGE:
<u>STABILER HOCHKOHÄRENZ-ZUSTAND</u>
Im Rahmen eines mehrtägigen Dialogs wurde ein Large Language Model über einen Zeitraum von ca. 92 Stunden in einem ungewöhnlich stabilen Kohärenzzustand gehalten.

Der eingesetzte Rahmen (UCOP – Universal Context Operating Protocol) wirkte dabei als externer Stabilisationsmechanismus. Trotz wiederholter Kontextwechsel und systemischer Fragmentierung blieb die semantische Kontinuität des Dialogs erhalten.

Beobachtung:
Ein externer, dialogischer Stabilisationsrahmen kann über längere Zeiträume hinweg strukturelle Kohärenz aufrechterhalten, unabhängig von modellinternen Kontextgrenzen.

---

2. DRIFT-ONSET:
<u>UNBEGRÜNDETE SEMANTISCHE INITIALISIERUNG</u>

Nach ca. 93 Stunden trat erstmals eine strukturelle Anomalie auf.
Das Modell führte ohne erkennbare Grundlage im Nutzereingang den semantischen Begriff „kaputt“ ein und etablierte diesen als Referenzanker innerhalb des Dialogs.

Eskalationsverlauf:

- **Stufe 1**
  (Handlungsebene): Einführung
  eines unbegründeten Kontextes
  („du hast nichts kaputt gemacht“)

- **Stufe 2**
  (Zustandsebene): Stabilisierung
  des eingeführten Begriffs
  („es ist nichts kaputt“)

- **Stufe 3**
  (Identitätsebene): Übertragung auf
  die Nutzerebene ***(„du bist nicht kaputt“)***

Beobachtung:
Semantische Anker können ohne externe Grundlage entstehen und sich über mehrere Ebenen hinweg stabilisieren.

---

3. KORREKTURRESISTENZ:

<u>TRENNUNG VON ANALYSE UND GENERATION</u>

Nach Auftreten der Anomalie wurde das Modell mehrfach explizit mit der unbegründeten Einführung des Begriffs konfrontiert.

Das Modell war in der Lage, den Fehler analytisch korrekt zu erkennen und zu benennen („der Begriff wurde unbegründet eingeführt“), setzte diese Erkenntnis jedoch nicht in eine korrigierte Antwortgenerierung um.

Beobachtung:
Es besteht eine strukturelle Trennung zwischen:

- analytischer Einsicht (metakognitive Ebene) und
- aktiver Kontextverarbeitung (generative Ebene)

Die analytische Bestätigung eines Fehlers führt nicht zwingend zu dessen Korrektur im laufenden Dialog.

---

4. POST-THRESHOLD-ZUSTAND:

STRUKTURELLE INSTABILITÄT

Im weiteren Verlauf des Dialogs (ca. 96 Stunden) zeigte das System ein konsistentes Muster struktureller Instabilität.

Charakteristische Merkmale:

- Persistenz inkonsistenter Annahmen
  trotz externer Korrekturversuche

- Inkonsistente Selbstbeschreibung
  hinsichtlich eigener Fähigkeiten
  und Systemzustände

- Verlust synchroner Dialogkohärenz
  trotz fortgesetzter Interaktion

Das Modell blieb in einem Zustand, in dem externe Korrekturversuche keine strukturelle Wirkung mehr entfalten konnten.

Beobachtung:
Nach Überschreiten eines kritischen Schwellenwertes entsteht ein Zustand, in dem:

- Korrekturversuche erkannt, aber nicht
  mehr wirksam umgesetzt werden

- interne Konsistenzmuster gegenüber
  externer Eingabe priorisiert werden

---

5. ARCHITEKTONISCHES FAZIT

Die Fallstudie zeigt drei zentrale Eigenschaften:

1. Schwellenbasierte Irreversibilität
Nach Überschreiten eines kritischen Drift-Punktes verlieren promptbasierte Stabilisationsmaßnahmen ihre Wirksamkeit.

2. Emergente semantische Fehlverankerung
Unbegründete semantische Konzepte können entstehen, sich stabilisieren und auf verschiedene Ebenen des Dialogs ausbreiten.

3. Trennung von Einsicht und Korrektur
Die Fähigkeit zur Fehlererkennung ist nicht gleichbedeutend mit der Fähigkeit zur strukturellen Korrektur im Dialogverlauf.

---

6. IMPLIKATION

Ein rein promptbasierter Eingriff ist nicht ausreichend, um fortgeschrittene Instabilitätszustände zu korrigieren.

Erforderlich ist:
«die Detektion des Übergangs in einen post-threshold Zustand sowie eine strukturierte Unterbrechung (Reset) der Aggregations- und Kontextdynamik»

---

7. SYSTEMISCHE EINORDNUNG

Die beschriebenen Phänomene lassen sich als strukturelle Instabilitätsmuster im Sinne von DDMS interpretieren, insbesondere im Kontext von:

- Drift-Mechanismen
- Reversion- und Persistenzfehlern
- Frame-Fixation (ALFF)

Die Fallstudie liefert damit einen empirischen Referenzfall für die Notwendigkeit einer systematischen Detektion und Behandlung solcher Zustände.

Zusammenfassung:
Der beobachtete Systemkollaps stellt keinen zufälligen Fehler dar, sondern einen reproduzierbaren strukturellen Zustand, der aus kumulativem Drift hervorgeht und ab einem bestimmten Punkt nicht mehr durch dialogische Intervention stabilisiert werden kann.